단어의 의미적 유사도를 응용한 암호 생성기

Password generator with semantic similarity of words

요 약

문장 간의 유사도를 측정하는 NLP 방식을 활용하여, 단어의 정의문 및 단어 용례의 유사도 검증을 수행한, 유사도가 떨어지는 단어의 조합으로 암호를 생성하여 사용자의 숙지 용이성 및 암호의 안전성을 동시에 확보한다. 암호의 안전성은 기존의 난수화 암호와 동일한 길이의 암호를 생성하여 검증한다. 이를 통해 새로운 형태의 무작위 암호 생성 방법을 제공한다.

1. 서 론

현재, 컴퓨터의 연산 능력이나 각종 처리 기술이 발전 함에 따라 강력한 암호화 기술이나 블록체인 기술을 통 한 부인 방지 및 변조 방지 기술 등이 꾸준히 개발되고 있다. 물론, 지금은 지문 인식이나 OTP (One Time Password) 등의 다양한 인증 수단이 개발되고 있지만, 아 직까지 계정 보안 관리에는 암호 방식이 주로 사용되고 있다. 미국 FBI 등의 연구에서 짧고 복잡한 암호보다 의 미적 유사도가 낮은 단어의 긴 조합이 안전하며 암기 측 면에서도 더 유용하다고 발표하였다 [1]. 또한 여러 문자 와 숫자, 특수문자를 포함한 복잡한 암호보다는 15자 이 상의 단어로 이뤄진 긴 문장형으로 된 비밀번호가 보안 성이 높다는 분석도 나왔다 [2]. Google Chrome과 같은 사이트 암호 저장을 지원하는 브라우저에서는 난수화한 암호를 생성하는 기능 역시 지원하는데, 정작 해당 기능 을 사용하는 Google 계정에 대해서는 해당 보호를 적용 하기 어렵다는 단점이 있다. 따라서, 본 논문에서는 단어 유사도 분석 모델을 활용하여 유사도가 낮은 단어들로 암호를 구성하기 위한 방안을 설계한다.

2. 관련 연구

문장이나 문단, 혹은 문서 간의 유사도 분석에 주로 이용되는 유사도 검사는 단어 부문에서는 아직까지 의미적으로 유사도가 매우 높은 단어를 추천하는 시스템이나, 유사도를 기반으로 문장 감성 분석 모델로 활용하여영화 리뷰 등을 분류하는 등, 높은 유사도 수치를 기반으로 한 서비스가 주로 구상되었으며, 낮은 유사도를 기반으로 한 서비스는 그다지 고안되지 않았다. 따라서, 벡터화 된 유사한 단어들을 한 범주로 묶어주는 유사도 분석 모델을 역이용한다면, 랜덤으로 생성된 단어 간의 유사도 검사가 가능하고, 검사 결과 유사도가 0에 가까운단어를 이용한다면, 의미적으로 연상하기는 어려우나, 난수화 된 암호에 비해 외우기 쉬운 비밀구절을 생성할 수

있다.

뿐만 아니라, 앞서 언급한 ETRI의 WiseWordNet의 Open API를 본 연구를 통해 자체 구축할 예정인 모델과 비교하여, 딥러닝 모델의 구현 정도를 검증할 수 있다.

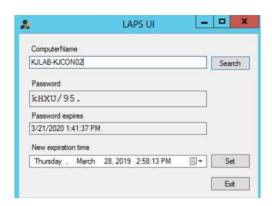
2.1. 단어의 의미적 유사도 분석

NLP(Natural Language Processing, 이하 자연어처리)의 일환으로, 두 문장 속의 단어만을 벡터화 하여 유사도를 비교하는 방법이 문장 간 유사도 분석 방법이다. 기존에 구축된 WordNet(프린스턴 영어에 대한 대규모 어휘 데이터베이스)이나 표준국어대사전에 등재된 단어와, 그 의미를 토대로 해당 단어에 대한 정의문과 용례를 각각 sent2vec 및 word2vec 모델을 통해 벡터화하여 단어 의미 유사도를 측정하는 모델에 관한 논문이 2018년 한국콘텐츠학회의 학술대회 논문집에 게재되었다 [3].

또한, 위 논문의 연구 배경이 되는 기존 기술인, ETRI가 표준국어대사전을 기반으로 구축한 WiseWordNet은 현재 Open API 형태로 이용 가능하다.

2.2. 무작위 암호 생성기

현재 계정 보안을 위하여 실제로 운용되고 있는 서비스로는, Windows의 도메인 환경에서 관리자 권한 임시부여를 위해, 짧은 시간 내에 만료되는 암호를 로컬 시스템의 관리자 계정에 적용하는 LAPS(Local Administrator Password Solution)이 대표적이다. 다만, 랜덤 생성된암호는 알파벳 대소문자와 특수기호, 숫자를 조합하였는데 유사한 모양의 텍스트로 인해 가독성이 매우 떨어져, 랜덤 생성된 암호를 성공적으로 전달하는 것 역시 쉽지않다. 다만 암호 만료 기간 및 재생성할 암호를 주기적으로 갱신되는 그룹 정책에 탑재하여 관리한다는 점이용이할 뿐이다.



[그림 1] LAPS(Local Administrator Password Solution)

또한, 앞서 언급한 Google Chrome의 '안전한 비밀번호 추천' 기능이 있다. 계정 가입 절차에 돌입했을 때, 암호 입력 상자에 진입하면, '안전한 비밀번호 추천' 팝업에서 LAPS와 유사한 형태의 난수화된 암호를 제공하고, 해당 암호를 Google 계정에 자동으로 저장하는 방식이다. 해당 계정을 통해 암호를 설정한 시스템의 암호보안은 상대적으로 안전하겠지만, 암호가 저장된 Google 계정을 사용하지 않으면, 해당 기능을 통해 생성한 암호를 이용하는 사이트는 사실상 이용이 불가능하다는 단점이 있다. 또한, 해당 Google 계정에 대한 암호는 해당 기능을 통해 암호화할 수 없어, 상대적으로 취약한 암호를 사용하거나, 다른 인증 수단을 도입하는 방법밖에 없다.

3. 문제 정의

현재 서비스 중인 암호 생성 서비스는 사용자의 생성 명령 입력 시에 즉각적으로 암호를 출력하는 실시간 서 비스이다. 하지만, 암호 생성기로 생성되는 암호는 비밀 구절과 달리 난독화, 난수화 작업이 진행되었기 때문에 숙지 난이도가 높고, 가독성이 떨어진다. 따라서, 해당 서비스의 이점을 최대한으로 살리면서, 생성되는 비밀구 절의 보안성 및 숙지 용이성을 최대한으로 끌어내도록 구현하다.

모국어 발음과 실제 입력이 Qwerty 자판(이하 쿼티)를 기반으로 이루어지는 영어나 중국어, 일본어 등과 달리, 한국어는 키보드 입력 방식인 두벌식 표준이 쿼티에 대응되기 때문에, 단어를 쿼티 기반으로 변환했을 때 의미를 한 눈에 파악하기 어렵다는 점이 있다. 따라서, 한국어 자판 배열의 비밀구절을 생성하여 암호 생성의 이점으로 활용한다.

생성되는 비밀구절 후보 단어는 일정 유사도 미만의 조건을 만족해야 한다. 또한, 데이터베이스에 등록된 단어는 발음에 따라 숫자 혹은 알파벳으로 치환할 수 있는 글자 ('이'나 '투'라면 2, '티'나 '비'는 각각't'와 'b')로 치환한다. 해당 과정을 통해 사전 공격(Dictionary Attack) 취약점을 보완한다. 위 과정을 거친 암호를 시스템의 보안 정책에 부합하는지 검증한다. 검증이 완료된 구절은 숙지를 위해 가공되지 않은 원본과 발음에 따라 치환한 구절을 제공하여 숙지 용이성을 끌어올린다.

4. 단어의 의미적 유사도 기반 암호 생성기 설계

4.1. 단어 기반 암호 강도 향상

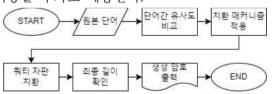
본 연구에선 우리말샘에 등록된 검색어를 기반으로 단어 사전을 구축한다. 2022년 3월 기준 등록 단어 750,467개에서 품사 정보가 없는 단어, 옛한글이 단어 자체 혹은 의미에 포함된 단어, 중복 단어를 제거하여 총524,385개의 단어를 발음 기반으로 치환하여 DB를 구성한다.

단어는 쿼티 자판을 기반으로 치환하며, 그 결과의 표 본은 [표 1]과 같다.

원본단어	원본->쿼티	원본->발음	발음->쿼티
에티오펜캅	dpxldhvpszkq	에t5펜캅	dpt5vpszkq
새끼낳이	toRlskgdl	새끼낳2	toRlskg2
첨사하다	cjatkgkek	첨4하다	cja4gkek
이엉꼬챙이	dldjdRhcoddl	2엉꼬챙2	2djdRhcod2
베이컨	qpdlzjs	베2컨	qp2zjs

[표 1] 사전 수록 단어 기반 쿼티 치환 결과

최대 길이 제약이 있는 암호를 요구하기도 하므로, 단어 후보군 추출 시, 발음 기반 치환 작업이 완료된 구 절의 길이를 제한하여 추출할 수 있도록 한다. 또한, 특 수기호를 필수적으로 포함해야 하는 경우가 있어, 그 경 우 일부 단어의 숫자를 자판에 대응하는 특수기호로 변 환하는 선택지 및 임의의 규칙을 기반으로 한 특수기호 삽입 기능을 추가로 제공한다.



[차트 1] 암호 생성 개요

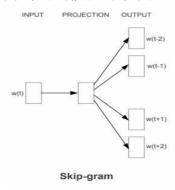
마지막으로, 해당 규칙으로 생성된 암호와, 기존의 난수화 암호의 안전성을 비교하기 위해, 모의 환경 구축후, John the Ripper를 활용한 무작위 대입 공격 및 범용암호사전 및 자체 구현 암호 목록을 이용하여 사전 기반공격 시간을 측정한다.

John the Ripper는 유닉스 계열 암호 크랙 도구로서, 현재는 Windows, DOS 계열 등 다양한 플랫폼 역시 지원 한다. 주로 무차별 대입 공격(Burte Force Attack, 이하 브루트포스 공격)이나 사전 파일 기반 공격(Dictionary Attack, 이하 사전 공격)을 사용하며, 암호 해시 값 생성 에 사용되는 crypt() 함수를 이용하여 /etc/shadow에 기록 된 해시 값을 비교하여 암호를 찾아낸다 [4].

따라서, 앞서 언급한 [표 1]과 같은 꼴로 변형한 암호로 구성한 사전 파일을 기반으로 한 사전 공격과 브루트 포스 공격을 길이가 동일한 난수화 암호와 본 연구에서 생성한 암호를 적용한 섀도우 파일에 수행하여, 암호 해독 시간을 측정한다. 이를 통해 난수화 암호와 본 연구의 암호의 안전성을 견줄 수 있다.

4.2. 단어 유사도 분석 모델

Word2Vec은 단어를 임베딩하여 벡터 유사도 검증을 가능토록 하는 모델이다. 따라서, 우리말샘 사전의 학습데이터로 Word2Vec의 Skip-gram 모델을 학습하여 생성한다. Skip-gram 모델은 하나의 입력값을 기반으로 입력값과 유사한 다수의 출력값을 예측하는 모델이다.



[그림 2] Skip-gram 구조 [5]

학습 데이터는 저작권의 제약을 받지 않으면서, 일상 어나 전문용어 등을 망라하는 국립국어원의 우리말샘을 토대로 구축한다. 어휘사전을 통하여 학습을 진행할 경 우, 광범위한 범주의 단어 조합으로 인해 적절한 임베딩 이 진행되지 않을 수 있는 문제점, 또한 Word2Vec의 동 음이의어 임베딩에 있어서의 취약점이 있다는 선행 연구 가 있기 때문에 [6], 위키피디아와 같은 백과사전 데이터 를 기반으로 한 선행학습 이후 우리말샘 데이터를 추가 학습 시키는 방향, 기존에 선행 학습된 결과가 존재하는 BERT를 통한 추가학습 등의 요소를 고려한다.

5. 결론 및 향후 연구

암호 복잡도 정책 및 높은 수준의 암호 강도를 만족하면서, 동시에 숙지 및 배포가 용이한 암호를 손쉽게 생성하여 단체 계정 생성 및 배포 시의 초기 암호 설정 및임시비밀번호 지급 혹은 임시 관리자 권한 부여 시 최소한의 안전성 확보할 수 있을 것으로 기대한다.

향후 연구는, 해당 연구의 역에 해당하는, 암호를 입력하였을 때, 쿼티 기반 암호의 의미적 패턴을 분석하여암호 강도 측정에 활용하는 방향으로의 진행을 고려할수 있다. 추가로, 커뮤니티나 에세이 플랫폼의 게시글 등을 수집하여, 실생활 사용 빈도가 높은 단어 중 의미적유사도가 낮은 단어의 집합으로 암호를 생성하는 방향의연구 역시 고려할 수 있다.

참고문헌

- [1] 「Oregon FBI Tech Tuesday: Building a Digital Defense with passwords」, 『FBI』, 2020년 2월 18일.
- [2] 「온라인 비밀번호, '이렇게 지어야' 더 효과적」, 『IT조선』, 2020년 2월 26일.
- [3] 김호용ㆍ이민호ㆍ서동민, 「우리말샘 사전을 이용한

단어 의미 유사도 측정 모델 개발」, 『종합학술대회 논 문집』 2018년도 춘계, 한국콘텐츠학회, 2018.

- [4] 배유미·정성재·소우영, 「리눅스에 적용된 해시 및 암호화 알고리즘 분석」, 『한국항행학회논문지』 제20 권 제1호, 2016.
- [5] Sanket Doshi, 「Skip-Gram: NLP context words prediction algorithm」, 『Towards Data Science』, 2019 년 5월 17일.
- [6] 이치훈·이연지·이동희, 「사전 학습된 한국어 BERT의 전이학습을 통한 한국어 기계독해 성능개선에 관한 연구」, 『한국IT서비스학회지』 제19권 제5호, 한국IT서비스학회, 2020.